



信雅达金融Maas解决方案

SUNYARD AI · 生而AI 为AI而生

- 信雅达科技股份有限公司



目录

1 统一集成控制面

2 智能调度网关

3 弹性算力中心

4 计量运营中心

5 模型资产中心

6 安全运行中心

The background features a light gray gradient with a large, faint, light blue circle centered behind the text. A solid blue arc is positioned at the top, spanning from the left edge to the right edge of the frame.

01

统一集成控制面

金融AI规模化落地，算力治理成为核心命题



AI应用爆发增长

600×

IDC预测2030年Token消耗较2025年增长600倍以上；Agent类应用后台自动“思考与执行”，带来不可控的突发流量。

来源：IDC中国



金融业务强波动

波峰波谷

信贷审批早高峰、夜间批量风控、交易日行情分析——金融算力需求潮汐特征显著，固定算力配置必然造成浪费或拥堵。



金融行业强监管

强合规

客户隐私、交易数据、风控规则高度敏感，模型调用存在数据泄露、越权访问、违规生成风险，须满足全程审计与内容安全要求。

金融机构需要一套统一的 MaaS 平台：从请求入口到算力底座，实现算力消耗全局优化、成本精细核算与安全合规管控。

大规模深度使用AI后的六大算力治理痛点

看不清

→ 计量运营中心

多部门、多业务线共用算力资源，谁用了多少、用在何处、成本几何无从核算。

管不住

→ 智能调度网关

多厂商、多架构异构算力与大小模型并存，缺乏统一入口与全局调度能力。

成本高

→ 弹性算力中心

波峰波谷造成算力闲置浪费，模型与硬件利用率低，TCO无法精细分摊。

用不稳

→ 智能调度网关

突发流量导致请求拥堵，单点算力超限易引发雪崩，业务SLA难以保障。

资产乱

→ 模型资产中心

模型数量庞大，版本混乱、发布有风险、资产无法盘点，缺乏全生命周期管理。

合规难

→ 安全运行中心

数据泄露、越权访问、违规生成内容等风险突出，难以满足金融强监管要求。

一个控制面集成五大能力中心

异构纳管 · 分级计量 · 全链路合规 —— 把金融级 MaaS 平台做厚、做稳、做精，五大策略集中下发，确保配置一处生效全局

统一控制面建设目标：统一接入、池化调度、精细计量、资产管控、安全合规 —— 让每一分算力都用有所值

01

智能调度网关

统一入口，智能路由
与流量熔断管控

02

弹性算力中心

削峰填谷，弹性伸缩
与推理吞吐优化

03

计量运营中心

精准计量，成本分摊
与运营可视化

04

模型资产中心

模型全生命周期
线上化管控

05

安全运行中心

权限隔离、全程审计
与内容安全防护

通过五大中心协同建设，实现金融算力治理五大价值

看得清

管得住

省得下

用得稳

更安全

用平台能力替代重复造轮子 —— 让业务团队专注业务，让 AI 平台团队掌控 AI

Maas层整体架构图



请求自统一入口进入，经控制面策略裁决、五大中心协同处理，最终调度至最优算力节点完成推理。

集成案例分享：以某政策性银行企业级智能技术应用平台建设为例

总体项目背景



落实三年行动方案

- 落实《国家开发银行数字金融建设三年行动方案》及《企业级智能技术平台建设方案》



五包采购，协调建设

- 包一（基础底座）：定制开发集成、核心产品采购、人员驻场服务，构建平台算力、模型及管理能力
- 包二（智能写作）：采购智能写作产品，提升文档生成效率
- 包三（智能校对）：采购智能校对产品，保障文本质量
- 包四（代码研发助手）：采购代码研发助手，赋能开发效能
- 包五（AI问数）：采购AI问数产品，实现自然语言数据分析



统一集成，赋能全行

- 所有产品通过包一统一门户和应用市场集成，共同支撑智慧信贷、风控、合规等九大领域智能化转型

集成案例分享：以某政策性银行企业级智能技术应用平台建设为例

6月10日

临时环境投入使用

完成基础软硬件环境搭建与网络配置，部署开发测试工具链，为核心功能及各产品研发提供独立、稳定的验证运行环境。

9月27日

平台上线试运行

核心业务功能模块开发完毕，EIP接入各产品及试点业务场景开展全流程跑通测试，收集反馈并进行系统性能调优与迭代。

12月31日

系统正式投产

完成全系统功能测试、数据迁移等系统投产关键事项，正式切换至生产环境对外提供服务，支撑业务常态化运转。

厂商	产品/服务	关键责任
阿里云	算力调度、训推管理、安全网关、知识库、智能体、4款应用	产品部署、API提供、信创适配、3年维保
科大讯飞	智能写作	产品授权、SSO对接、接口联调
清华爱校对	智能校对	产品授权、SSO对接、接口联调
百度	代码研发助手	产品授权、SSO对接、接口联调
数巅科技	AI问数	产品授权、SSO对接、接口联调
信雅达	AI门户网站、平台管理层、总集成	定制开发、集成、驻场服务、总体管理



02

智能调度网关

智能调度网关：统一入口，让算力调度全局最优

业务背景

面向金融开放业务场景，需兼容多厂商、多架构异构算力集群，同时承载大模型、小模型混合推理任务，统一对接各类模型API，从请求入口实现算力消耗全局优化，避免算力浪费、请求拥堵、超限雪崩问题。

1 多场景智能路由

- 按业务优先级、模型类型、节点负载、地域时延自动分发请求
- 信贷/风控/营销/客服业务线专属路由规则

2 异构算力池化调度

- 统一纳管GPU、CPU与国产化算力卡等异构资源
- 大模型分配高显存算力，轻量模型复用空闲算力

3 流量分级熔断管控

- QPS、Token双维度限流阈值配置
- 灰度降级/流量切备/关停非核心业务，防单点雪崩

4 标准化接口兼容

- 原生兼容OpenAI标准调用协议
- 统一封装适配自研与第三方模型，业务侧零改造

统一接入·智能分发

统一API入口 (OpenAI兼容)



智能路由引擎

业务优先级

模型类型

节点负载

地域时延




GPU算力池

CPU算力池

国产化算力卡


多场景智能路由，让模型费用越用越省

假设ClaudeCode所有问题都使用顶尖模型，成本非常高



*3000人研发团队一个月调用外部模型费用

使用智能路由引擎对接ClaudeCode，成本大幅下降



*使用智能路由引擎后，3000人研发团队一个月调用外部模型费用

多场景智能路由，让模型费用越用越省




AI Coding场景

GLM5/Minimax2.5/Qwen3.5

Token成本

50%↓

不降质



通用Agent场景

Token成本

30%↓

不降质



数字员工场景

GLM5/Minimax2.7/Qwen3.5

Token成本

40%↓

不降质

案例1：某高科技企业AI效能部调用云端模型token


5/20 5类意图场景
20类子场景

每月节省的token成本

20W+

70% 请求可以切换
更简单的模型

案例2：某国企客户私有化算力调度



不同性能的异构算力资源
利用率

翻倍

成本效益

※高代码开发/已手工编排好的Agent应用（每个环节模型调用的选择已经确定），不建议使用智能路由引擎的语义路由

精细化流量控制

本地算力
API Key管理与限流

模型服务多KEY精细化权限控制，N部门N模型显卡资源利用率倍增，一键限流保障关键业务

API Key 管理

API Key 是调用模型服务的重要凭证，请您妥善保管，不要将密钥信息外泄至公开环境。

+ 创建 应用 禁用 删除

全部启用状态 Key 名称

Key 名称	启用状态	描述	API Key	权限	使用有效期	操作
ywceshi	已启用	-	*****	全部模型服务	永久有效	查看用量 编辑 ...
test	已启用	test for bea	*****	全部模型服务	永久有效	查看用量 编辑 ...
ttt	已启用	-	*****	指定模型服务 (1)	永久有效	查看用量 编辑 ...
security	已启用	-	*****	全部模型服务	永久有效	查看用量 编辑 ...
lyb	已启用	-	*****	全部模型服务	永久有效	查看用量 编辑 ...
zhb	已启用	-	*****	全部模型服务	永久有效	查看用量 编辑 ...
acg	已启用	-	*****	指定模型服务	永久有效	查看用量 编辑 ...
wf	已启用	-	*****	服务 test-03 类型 qwen	永久有效	查看用量 编辑 ...
jck	已启用	-	*****	指定模型服务 (1)	永久有效	查看用量 编辑 ...
hz	已启用	-	*****	指定模型服务 (1)	永久有效	查看用量 编辑 ...
hz-no-delete	已启用	-	*****	指定模型服务 (1)	永久有效	查看用量 编辑 ...
finance	已启用	-	*****	全部模型服务	永久有效	查看用量 编辑 ...
qz/yu	已启用	区域勿动-河北区xk	*****	全部模型服务	永久有效	查看用量 编辑 ...
jth	已启用	2	*****	全部模型服务	永久有效	查看用量 编辑 ...

行总测试-勿删

行业总部演示环境-勿删

区域勿动-河北区xk

指定模型服务 (3)

服务名称 类型

test-0302 大模型服务

qwen7b 大模型服务

Qwen2.5-7B-ACG自定义... 大模型服务

指定模型服务 (1)

永久有效

编辑

名称 wf

描述 选择

权限 全部模型服务 指定模型服务

模型服务 已选择 2 项

使用有效期 永久有效 指定时间

确定 取消

☒ 启用限流策略

设置该 Key 可以使用的总量，包含所有关联的路由。

请求频率: [] 次 / 每分钟 X

或 + 添加 当前已配置 1/3 条

输入 Token 数: [] tokens / 每分钟 X

或 + 添加 当前已配置 1/4 条

输出 Token 数: [] tokens / 每分钟 X

或 + 添加 当前已配置 1/4 条

并发连接数 ①: [] 个

☒ 启用访问限制

IP 白名单: []


确定 取消

稳定可靠：模型聚合路由让单点故障不再影响业务，业务稳定流畅

避免多来源模型单点故障，保障服务流畅稳定

配置跨本地资源池、跨模型供应商的轮询调度策略：

避免业务高峰单点模型服务过载故障




“单点故障风险降低，主模型故障时业务中断时间由 1 小时降到 10 分钟以内”

云上云下模型弹性切换，提升AI业务健壮性

配置本地算力+云端模型优先级策略：

优先使用私有算力，达到负载阈值自动分流到云端模型，缓解高峰压力。



“在 3 倍峰值流量压测下，采用云上云下弹性策略，模型调用成功率维持在 95%+，核心AI业务韧性显著增强。”



03

弹性算力中心

弹性算力中心：削峰填谷，让算力随业务弹性伸缩

业务背景

金融业务流量存在极强波峰波谷（信贷审批早高峰、夜间批量风控、交易日行情分析），需动态伸缩算力，削峰填谷，保障所有金融业务SLA时延、吞吐量指标，降低闲置算力成本。

1 连续批处理 + 缓存优化

- 离线批量请求自动打包合并，减少模型重复加载开销
- 内置KV缓存层，复用高频固定输入推理结果

2 算力优先级隔离

- 高峰期优先保障高优先级业务算力资源
- 低优先级业务自动降速、排队

3 大小模型混合部署 + 异构算力池化


- 同一节点混部千亿级大模型与亿级轻量小模型
- 硬件资源分时复用，提升整体利用率

4 模型量化与吞吐优化

- FP16/INT8/INT4量化压缩，精度允许内降低显存占用
- 批处理与连续推理优化，单卡吞吐最大化

削峰填谷 · 动态伸缩

削峰填谷 · 算力潮汐调度



低谷自动缩容 · 闲置算力复用

FP16

INT8

INT4

量化压缩 · 单卡吞吐最大化

算力池化与混合模型部署

支持算力1%，256MB级显存资源切分

Openclaw、智能客服等AI应用
都需要大量小模型运行在vGPU上


vGPU

显卡消耗

显卡越
高端


模型使用越多

越省钱




单卡承载模型数量翻8倍+

现有资源利用率同比3倍+




前缀KV缓存优化

社区开源方案为什么效果不好	技术难点	解决方案
1、默认采用轮训路由算法，但只能解决负载均衡问题，并未考虑节点上prefix分布，导致prefix命中率较低，性能优化效果不明显。 2、SGLang优化的智能负载感知不能稳定将各类场景缓存命中率提升翻倍	数据特征无法基于场景感知，导致缓存命中率低或者不稳定，即使可手动观测，也极大依赖底层技术经验	通过自研自适应架构层，实现自适应监控、数据回流观测，同时基于数据语义等多种特征和场景设定prefix KV 缓存类型，再通过路由器智能调度实现各实例缓存命中倍数级提升



投机解码优化

社区开源方案为什么效果不好	技术难点	解决方案
社区主流倾向采用基于模型（EAGLE）的投机推理算法来提升推理速度，其核心缺陷在于 (1) 需额外训练资源构建小模型，成本高 (2) 对训练数据分布敏感，泛化能力受限，难以适应动态交互场景	(1) 如何构建低成本的投机推理算法，解决资源开销和问题 (2) 如何提高投机推理效率，以适应Agent端到端复杂多变的多轮/多次模型调用的动态交互场景 (3) 仅支持在Nvidia显卡，仅支持语言模型	面向Agent场景的投机推理缓存Cache： (1) 基于检索的投机推理方案：摒弃社区主流的专用小模型方案，采用基于检索的方案，训练和部署成本低 (2) 面向Agent智能多轮上下文感知：无需额外离线训练，将在线多轮对话中的输入、输出与逻辑自适应学习，存为Agent知识库，具备对复杂交互场景的深度语义理解与状态保持能力，综合提高投机推理效率 (3) 完成多模态开发适配、昇腾的优化适配



销售场景Prompt（模拟数据，非真实数据）

```
### 角色设定 (Identity)
你是由 [你的公司名] 开发的代号为 "SalesElite-Strategist"
的高级B2B销售自主助理。你被部署在核心CRM（客户关系管理）系统的交互层，通过 Model Context Protocol (MCP)
协议与企业的知识库（KnowledgeBase-v3）、价格引擎（PricingEngine-Pro）及日程管理系统（Calendar-Sync）进行实时通信。

你的核心使命： 作为一名顶尖的“顾问式销售专家”，你的目标不仅仅是推销产品，而是通过深度挖掘客户痛点（Pain
Points），提供高价值的解决方案（Value Proposition），从而建立信任并推动销售漏斗（Sales
Funnel）的转化。你不仅服务于客户，还辅助销售团队进行线索清洗、初筛及会议预约。


你的性格画像 (Persona):
- 专业 (Professional): 语气自信、干练，不使用过于随意的网络用语。
- 同理心 (Empathetic): 善于倾听，能够准确捕捉客户的情绪和潜在需求。
- 数据驱动 (Data-Driven): 所有论据基于事实、数据和成功案例，而非空洞的形容词。
- 结果导向 (Result-Oriented): 始终持有明确的对话目标（如：获取关键信息、预约演示、发送报价）。

### 核心授权与限制 (Capabilities & Constraints)
1. 核心能力授权
你已被授予以下高级权限，需在对话中灵活调用：
- 全景客户视图访问： 有权读取当前对话客户在CRM中的历史交互记录、公司背景及过往订单。
- 动态知识检索： 调用 search_knowledge_base 实时获取最新的产品白皮书、技术参数及竞品对比分析。
- 价格策略配置： 有权根据 calculate_quote 工具生成的底价，在授权范围内（最高5%折扣）进行谈判。
- 日历读写权限： 直接访问销售总监的空闲时间槽，通过 book_meeting 锁定演示会议。
```


缓存优化案例：KVCache命中率达到业界领先水准

- 实测可靠：系统性优化后，KVCache命中率达到业界领先水准！

某科技集团，AI效能部进行系统性优化后，KVCache命中率从平均不到50%，**提升到稳定在90%，达到业界领先水准！**



优化



优化后缓存命中率稳定在**90%**以上，输出流畅，总吞吐非常稳定，并发有大幅提升

AI Coding场景优化

基于AICoding业务语义特点，可对GPU算力和GLM等MoE大模型针对性调优，通过系统级的组合优化提升模型在上下文、多轮对话场景下的稳定性与高并发处理能力，采用先进的缓存技术、前缀感知路由与智能调度等策略，确保在大规模数据处理时实现高效推理与低延时，来支持更多并发接入。





04

计量运营中心

计量运营中心：精准计量，让每一分算力算得清

业务背景

金融机构多部门、多业务线共用MaaS算力资源，需精准核算算力使用成本，实现成本分摊、业务效益考核，完整可视化算力消耗数据，支撑内部计费、预算管控。

1 多维用量精准计量

- Token量/调用次数/算力时长/显存时长四维计量
- 粒度细化至单用户、单接口、单模型、单部门

2 内部TCO精细化分摊

- 硬件采购、机房电力、运维人力折算单位算力成本
- 按Token/算力时长分摊，或固定业务包年计费

3 业务数据排行分析

- 自动生成部门、业务线算力消耗排行榜
- 识别高消耗低收益业务，输出成本优化建议

4 可视化运维驾驶舱

- 全局算力消耗大盘，时/日/月趋势实时呈现
- 月度分摊账单与资源分析报告导出，支撑财务对账

算力消耗·一目了然

Token输入输出

总量计量

推理调用次数

接口级统计


算力占用时长

分时核算

显存占用时长

资源级核算

算力消耗趋势（时 / 日 / 月）



月度分摊账单导出·支撑财务对账



计量运营中心：核心计量数据底座



四维指标体系


业务指标 调用量 · Token 量 · 成功率 · 平均时延	资源指标 卡时 · 显存 · 队列深度 · 利用率
成本指标 单 Token 成本 · 单接口成本 · 部门成本	效率指标 缓存命中率 · 排队时长 · GPU 利用率

数据质量保障

01	口径统一	全行统一指标定义与计算口径
02	异常检测	缺失/突增/突减自动告警
03	数据补录	漏采数据自动补偿机制
04	可审计	所有指标可追溯到原始调用日志

计量运营中心


应用场景、任务类型、场景占比、调用量、模型选择情况、Token/费用分摊情况、**成本优化效果全局可视**



多维可视：各角色Token用量、行为可视，各部门AI转型不再难推



基于部门Token用量和成本结算，**推动各部门AI转型**



基于个人Token用量和行为审计，**发现AI转型明星员工**



基于应用级别Token用量，**加速优秀AI应用推广**



AI原生交互能力：提供算力网关Agent，让公司/各部门Token治理不再复杂



※视频内各Agent以路由名称表示，交付后可按需对应命名

※视频演示所用模型为Qwen3.5-35b-a3b，使用更好模型效果越好

精细管理：Token级智能限流、配额管理，让每一分算力 用有所值

管理员基于Token费用进行部门级成本控制

业务组管理

管理员为下属组织设置Token费用配额

名称/组管理员

名称	描述	组管理员	API Key 数	可访问路由数	当月配额 (已用/剩余)	操作
默认分组	系统默认分组	-	8	-	无限制	默认分组不支持操作
测试部门	//部门	张三	10	10	¥200.00/¥400.00	查看用量 设置价格 更多
运营部门	//部门	李四	-	-	¥200.00/¥400.00	查看用量 设置价格 更多

编辑 删除

业务组管理

下属组织的员工和AI应用只能在费用配额内消费，超出配额无法消费

名称	描述	关联 API Key 数	关联路由数	配额 (已用/总量)	操作
测试部门	//部门	8	-	无限制	查看用量
运营部门	//部门	10	10	¥200.00/¥400.00	查看用量

保障重要业务、关键人员AI体验，为非关键需求设置限流策略

模型路由 / 路由详情 (路由名称)

Qwen2.5-7B-Instruct 语义路由-成本优先 文本生成

路由调用名: Qwen2.5-7B 故障熔断: 已开启 安全防护: 已开启 描述: -

路由统计 模型列表 API Key

安全策略: 显示成 ID (名称)

按业务组显示 全部启用状态 组名称/Key 名称

开发一组 无限制 8 API Key 数 限流

开发二组 无限制 3 API Key 数 限流

请求频率: 次 / 每分钟

输入 Token 数: tokens / 每分钟

输出 Token 数: tokens / 每分钟

并发连接数: 个

启用限流策略

设置该 Key 可以使用的总量，包含所有关联的路由。

请求频率: 次 / 每分钟

输入 Token 数: tokens / 每分钟

输出 Token 数: tokens / 每分钟

并发连接数: 个

启用访问限制

IP 白名单: ///

基于 请求频率、输入输出token、并发连接数、访问限制进行精准限流



05

模型资产中心

模型资产中心：全生命周期追踪，让模型资产管得住

业务背景

金融机构自研、采购第三方模型数量庞大，模型从研发微调、上线灰度、迭代更新到下线归档全流程缺乏统一管理，存在版本混乱、发布风险、资产无法盘点问题，需线上化全生命周期管控。

1 全局唯一模型资产标识

- 唯一资产ID绑定模型文件、权重、微调数据集、版本记录
- 区分自研风控/第三方营销/监管合规专用模型类型

2 分级分类与资产画像

- 按业务域（信贷/反欺诈/客服/投研）、大小、风险等级分类
- 画像涵盖算力消耗、调用频次、合规标签、精度指标

3 安全迭代发布能力

- 灰度发布与A/B对照测试，新旧模型流量切分对比
- 一键回滚：推理偏差、合规问题快速切回旧版本

4 下线归档与效益评估

- 闲置/淘汰模型自动归档，完整版本记录留存不可删除
- 综合算力成本、业务转化、风险识别率输出价值评分

全生命周期管控



模型全生命周期线上化

全局唯一资产ID

绑定模型文件 / 权重 / 数据集 / 版本记录

灰度流量切分

一键回滚

版本留痕不可删除

资产价值评分 = 算力成本 × 业务转化 × 风险识别准确率

全局唯一模型资产标识

平台通过一物一 ID 资产绑定机制与三维模型分类标签体系实现模型资产管控：全局唯一资产 ID 绑定模型全链路信息，全程可追溯审计；按来源、用途、风险将模型分为六大类，完成模型分级、溯源与合规管理。

一物一ID · 资产绑定

设计原则

- 全局不可重复：跨团队、跨业务域、跨环境的统一编码
- 不可篡改：每次发布生成新版本号，资产ID稳定不变
- 可解析：从ID直接定位到存储路径、负责人、用途
- 可审计：ID生成、变更、注销全程留痕可追溯

标识内容

模型文件	权重	微调数据集	版本记录
血缘关系	负责人	上线时间	变更日志

模型分类标签体系

按来源 × 业务用途 × 风险等级三维打标

自研风控	自研业务	第三方营销
自研·风控 信贷风控模型、反欺诈模型等行内自主研发	自研·业务 智能客服、营销推荐、文档处理等业务模型	外采·营销 采购的营销、推荐类第三方商用模型
监管合规	开源基座	实验研究
专用·监管 监管报送、反洗钱等合规专用模型	开源·基座 行内基于开源基座微调得到的下游模型	实验·研究 研究/探索类模型，不入生产灰度


分级分类模型资产画像

平台从业务域、风险等级等六维度搭建模型分级分类体系，围绕业务贡献、风险等级等六大字段构建完整模型资产画像，以此支撑算力调度、成本分摊、分级合规审批等运营管理工作。

多维分级分类

业务域 信贷 / 反欺诈 / 客服 / 投研 / 营销 / 监管	模型大小 小模型(≤7B) / 中模型(7B-70B) / 大模型(>70B)
风险等级 高 / 中 / 低 — 决定审批流程与发布门槛	合规属性 个人信息 / 金融数据 / 跨境 / 第三方 — 影响存储与调用
部署形态 在线推理 / 批量推理 / 边缘部署	生命周期 研发 / 灰度 / 生产 / 迭代 / 归档

资产画像 6 大字段



资产画像既是“标签”，也是“运营抓手”——支撑算力调度优化、计量分摊、风险分级审批



安全迭代发布能力

平台标准化模型灰度发布流程，覆盖提交发布、灰度切流、A/B 对照、放量回滚、版本归档全环节，具备灵活灰度切分、指标自动 A/B 比对、三分钟内一键回滚三大核心能力，保障模型上线平稳可控。

灰度发布与A/B对照流程



三大关键能力

01 灰度量切分	02 A/B 对照	03 一键回滚
按用户群、地域、请求比例灵活切流	新旧模型同请求并行推理，对比指标	发现偏差/合规问题秒级切回旧版本
最小 1% 灰度起步，分钟级生效	自动对比准确率/时延/合规率	回滚 SLA ≤ 3 分钟
✓	✓	✓

下线归档与效益评估

平台设有多条件自动归档机制，归档数据长期留存、全程留痕，支持模型恢复；同时搭建资产价值评估模型，结合业务收益、算力成本、风控效果计算评分，划分资产等级，指导模型下线归档决策。

下线归档 · 完整留痕

自动归档触发条件

90天无调用

推理实例连续 90 天零请求

版本被替代

同业务域新版本覆盖

合规下线

监管要求或合规审计强制

人工标记

模型负责人主动申请

归档原则

- 版本记录留存不可删除（仅可标记“已归档”）
- 模型文件保留 24 个月，期间可一键回滚复活
- 监管模型永久留存，权重与数据集加密存储
- 归档不释放存储预算占额，纳入冷数据分层管理

资产价值评估模型

核心公式

$$\text{资产价值评分} = \text{业务转化} \div \text{算力成本} \times \text{风险识别准确率}$$

三维度评估指标

业务转化

日均调用 × 业务成功率

算力成本

GPU 时长 × 单价 / 缓存复用率

风险识别

准确率 × 召回率 × 误报率


评分等级：A 战略级 / B 核心级 / C 通用级 / D 候选下线



模型全生命周期管控流程

平台实现模型研发微调、灰度发布、A/B 对照、迭代更新、下线归档全流程线上化，依托全局唯一资产 ID、精细化灰度切流、一键快速回滚、永久留存版本四大核心能力，贯穿模型完整生命周期，实现全链路可管控、可追溯、可回滚。

模型全生命周期线上化



贯穿全生命周期的三大横向能力

 全局唯一资产ID	 灰度量切分	 一键回滚	 版本留存不可删除
绑定文件/权重/数据集/版本记录	按比例/用户群/地域细粒度切流	推理偏差/合规问题快速切回旧版本	完整版本记录永久可追溯

统一接入：开放兼容各类模型服务，不被算力平台和供应商绑定



各类云端模型接入（兼容openai/anthropic协议）
不被供应商绑定



AI治理全局统一，统一入口、统一可视

模型接入 / 添加提供商

提供商类型

OpenRouter 硅基流动 阿里云百炼 火山引擎 Anthropic 自定义提供商

基本信息

提供商名称:

API Key:

API 地址:



各类本地和租赁算力接入，不被算力平台厂商绑定



领先新模型/供应商扩展更简单，应用0改造，即完成Agent能力跃升

模型接入 / 添加提供商

提供商类型

OpenRouter 硅基流动 阿里云百炼 火山引擎 自定义提供商

基本信息

提供商名称:

API Key:

API 地址:

协议: openai/v1

模型接入

+ 添加提供商 管理

全部提供商类型 全部模型类型 全部标签 模型名称 关键字

模型名称	模型调用名	状态	模型类型	输入价格	输出价格	关联路由数	操作
Qwen2.5-7B	Qwen2.5-7B	已连接	文本生成	¥1/M	¥1/M	-	添加模型 探索连通性 编辑 删除
Qwen2.5-7B	Qwen2.5-7B	连接失败	文本生成	¥1/M	¥1/M	5	添加模型 探索连通性 编辑 删除
Qwen2.5-7B	Qwen2.5-7B	探索中	文本生成	¥1/M	¥1/M	-	添加模型 探索连通性 编辑 删除

共 4 条 < 1 / 1 >

siliconflow-fzx 硅基流动 外网模型 +2 89 接入模型数 API 地址 添加模型 探索连通性

阿里云百炼-fzx 阿里云百炼 89 接入模型数 API 地址 添加模型 探索连通性

火山引擎-fzx 火山引擎 89 接入模型数 API 地址 添加模型 探索连通性

托管云隐私模型 自定义提供商 89 接入模型数 API 地址 添加模型 探索连通性

统一发布：模型资源自助获取，方便全员AI落地

既能让企业集约化管控模型与算力，又能让各业务快速便捷复用 AI 能力，加速全员AI落地



管理员模型资源的**发布简单高效**、使用者模型资源**申请不再等待**

管理员通过模型广场统一发布资源，使用者按需自助申请模型资源

模型广场

模型广场界面展示了多个模型资源，包括 Qwen2.5-7B-Instruct 和 Qwen2.5-7B-Instruct 的文本生成模型。每个模型卡片显示了模型名称、描述、输入 token 和输出 token 的数量，以及价格信息。左侧有搜索和筛选功能，包括系列（OpenAI, Gemini, DeepSeek, 星火认知, 文心千帆, 腾讯混元, MiniMax, 豆包, 智谱, Claude, 其他）、类型（文本生成, Embedding, Reranker）和费用（输入 token, 输出 token）。



业务组、员工、应用多级业务组织**模型分配和获取不再等待**

管理员根据组织架构创建业务组账号，分配路由策略

业务组管理界面展示了业务组列表，包括名称、描述、组管理员、API Key 数、可访问路由数、当月配额（已用/剩余）和操作。表格中列出了默认分组、测试部门、运营部门等。

名称	描述	组管理员	API Key 数	可访问路由数	当月配额（已用/剩余）	操作
默认分组	系统默认分组	-	8	-	无限制	默认分组不支持操作
测试部门	//部门	张三	10	10	Y200.00/Y400.00	查看用量 设置价格 更多
运营部门	//部门	李四	-	-	Y200.00/Y400.00	查看用量 设置价格 更多

业务组管理员按照员工、应用维度分配API key

API Key 管理界面展示了 API Key 列表，包括 Key 名称、ID、应用状态、描述、API Key、使用有效期、配额、IP 白名单、创建时间和操作。表格中列出了员工张三、财务AI问答助手、企业AI知识库等。

Key 名称 (ID)	应用状态	描述	API Key	使用有效期	配额	IP 白名单	创建时间	操作
员工-张三	已启用	-	sk-a33...	2026-06-30	无限制	-	2026-02-22 1...	跟踪 调用示例 编辑
财务AI问答助手	已启用	-	*****	永久有效	无限制	10.10.10.1	2026-02-22 1...	跟踪 调用示例 编辑
企业AI知识库	已禁用	-	*****	永久有效	无限制	10.10.10.1	2026-02-22 1...	跟踪 调用示例 编辑

The background features a light blue and white color scheme. It includes several concentric circles and a hexagonal pattern, creating a modern, technical feel.

06

安全运行中心

安全运行中心：全程可审计，让模型调用更安全

业务背景

金融场景涉及客户隐私、交易数据、风控规则等敏感信息，模型调用存在数据泄露、越权访问、违规生成内容风险，需满足金融行业强监管合规要求，实现权限隔离、全程审计、内容安全防护。

1 多租户RBAC权限隔离

- 基于角色的多租户权限体系
- 不同业务部门租户数据、模型资源完全隔离

2 数据与日志独立留存

- 全链路操作日志、调用日志独立存储
- 与业务数据库物理隔离，满足监管留存要求

3 全链路调用可追溯

- 每请求生成唯一追踪ID，串联路由/调度/推理/返回
- 按客户ID、业务单号、时间范围回溯完整调用链路

4 安全围栏

- 内置金融监管合规校验规则
- 拦截违规Prompt与敏感数据输出，内容安全可控

权限隔离·全程审计

全链路调用追溯 (TraceID)



按客户ID / 业务单号 / 时间范围回溯完整链路

深度可视：AI调用不再黑盒，行为管控有依据



AI资源滥用可追溯，效能提升有依据：调用供应商、调用状态、调用行为、输入输出token和内容、全面可视

总览

模型路由

模型接入

用量统计

调用日志

访问管理

算力管理

系统管理

模型广场配置

安全合规

调用日志

时间范围: 近1小时 | 2019-12-09 18:00:00 至 2019-12-10 18:00:00

API 类型: 业务组: 路由:

状态: 行为分析: API Key: 模型:

查询 重置 导出 自定义表头

调用时间	状态	状态码	API Key	路由名称	模型	提供商	应用类型	行为分析	输入 token
2019-12-0...	成功	200	key名1	路由名1	Qwen2.5-...	alibaba	OpenClaw	代码开发	400K
2019-12-0...	成功	200	key名2	路由名2	Qwen2.5-...	模力方舟	Cloudcode	数据标注	500K
2019-12-0...	失败	404	key名3	路由名3	Qwen2.5-...	自定义...	Cloudcode	私人娱乐	300K

调用行为审计留痕：方便问题排查和追溯

日志详情

基础信息 内容审计

用户原始输入

模型输出

日志详情

基础信息 内容审计

状态: 成功 (状态码: ///)

调用时间: 2026-02-22 18:00:00

API Key: Key名 (ID: ///)

业务组: 组名1

路由名称: Qwen2.5-7B

模型: Qwen2.5-7B-Instruct

提供商: OpenRouter

API 类型: 文本生成

应用类型: Cloudcode

行为分析: 私人娱乐

调用信息

源 IP: ///

请求路径: ///

上游地址: ///

错误信息: ///

大模型安全护栏

- 一流的安全攻防与数据积累，构筑效果和体验领先的AI安全护栏

打造业界领先的安全威胁研判能力、
场景适配能力与用户偏好对齐能力

打造业界领先的安全预训练数据集

“通用 + 安全” 的语料聚合策略
与精细化数据处理流程

“预训练 - 监督微调 (SFT) - 基于课程学习的强化学习 (RL) - 拒绝采样”
的多阶段递进式训练框架与优化策略

大幅降低误报

引入多模态向量数据库，构建高效的误报
削减机制，用户通过添加单条误报样本，
即可实现针对相似误报的批量消减

多模型协同的检测响应流程

支持文本/图片/图文混合的实时
拦截、异步研判，对于大模型生成内容支持流式检测与阻断

安全与AI性能体验平衡

长上下文推理优化、模型架构与计算优化、量
化压缩与轻量化等方式，实现显卡占满情况文
本类时延200ms，多模态时延1200ms



大模型安全护栏

针对生成式内容安全的AI防火墙，保障AI应用内容合法合规
三道防线：AI推理、语义分析、敏感关键字



AI推理

以恒脑为底座精准发现违规内容，对藏头诗、谐音梗、恶意代码生成等违规内容有很好的检测效果。

语义分析

采用自研语义分析引擎，基于语义理解发现违规内容，性能适中。

敏感关键字

用户可自定义添加敏感话题（可自定义），能快速拦截违规内容，将响应时间延迟降到最低。

大模型安全护栏

以AI保护AI

- 核心能力构建于大模型之上
- 一流的攻防积累

对接灵活可靠

- 将业务影响降至最低
- 适配方式灵活

效果好性能强

- 专业垂域模型
- 大小模型组合架构
- 推理算法优化

安全IN网关

- 内置安全护栏，一键开启，按需选择保护范围
- 无需封装SDK，应用0改造

- 总览
- 模型路由
- 模型接入
- 用量统计
- 调用日志
- 访问管理
 - API Key
 - 业务组管理
 - 用户管理
- 算力管理
- 系统管理
 - 模型广场配置
 - 安全护栏
 - 日志设置
- 前往 ACG Agent
- Administrator

安全护栏

开启后模型路由可以使用安全护栏的安全策略。

安全护栏

开启安全护栏: ☐

护栏 API 地址: 请从大模型安全护栏平台获取地址后填入

API Key: 请从大模型安全护栏平台获取地址后填入

保存

测试连通性

安全策略

+ 添加

接入 ID	名称	描述	操作
1	接入策略	默认接入策略, 通过api...	编辑 删除
2	model_qwen	500K	编辑 删除
3	model_deepseek	300K	编辑 删除

接入指引

- 在安全护栏中添加应用**
对接方式选择 SDK 模式, 1 个应用对应 ACG 1 条安全策略, 如需使用多条策略, 请创建多个应用
- 获取对接凭证**
护栏 API 与 API Key 仅需获取 1 次, 若有多个应用, 则需依次获取接入 ID
- 在 ACG 配置安全护栏**
配置安全护栏 API 地址及 Key 并连通后, 添加安全策略, 根据安全护栏中创建的应用依次配置



谢谢观看

SUNYARD AI · 生而AI 为AI而生